

Treinamento de Modelo de Aprendizado de Máquina Para Identificação De Locutor

Lucas Gabriel Castro Medeiros Da Silva

Natal, 13 de Dezembro de 2025

Resumo: O objetivo do estudo foi implementar um modelo de Aprendizado de Máquina para realizar a tarefa de Identificação de Locutor em inputs de áudio. Então foi implementado um modelo com arquitetura híbrida *Encoder-Classifier*, utilizando a base de dados LibriTTS (Zen, 2019), subsets train-clean-100 e train-clean-360, fornecida pela Google LLC e licenciada sob Creative Commons Attribution 4.0 International License. O modelo atingiu 99.14% e 98.67% de acurácia respectivamente nos *datasets* utilizados.

1 - Introdução

Este projeto tem como objetivo a implementação de um modelo de Aprendizado de Máquina na tarefa de Identificação de Locutor ([Speaker Identification](#)), que é uma das tarefas mais presentes no uso da Inteligência Artificial atualmente, que está presente em sistemas de autenticação biométrica, em em forense digital são exemplo de onde essa tarefa pode ser aplicadas. O trabalho apresenta uma solução baseada em Aprendizado Profundo para identificação de locutores utilizando um modelo de arquitetura híbrida, combinando embeddings gerados por um modelo pré-treinado com uma rede neural treinada com esses embeddings para classificar os locutores fornecidos pela base de dados utilizada.

O sistema foi avaliado em dois experimentos utilizando duas bases de dados de tamanhos diferentes do corpus LibriTTS para melhor extração de métricas do comportamento do modelo em diferentes dados.

2 - Fundamentação Teórica

A Identificação de Locutor é uma tarefa que consiste em determinar a identidade de um locutor a partir de uma amostra de sua voz, como um “captcha de voz”. A voz tem suas características extraídas e transformadas num vetor linear de 192 dimensões, representando as features de uma determinada voz, esses vetores então são comparados com outros vetores de outras vozes através da [similaridade do cosseno](#) entre esses vetores. Onde um vetor A é similar a um vetor B, se o ângulo entre eles for igual ou dentro de um limiar (*threshold*) aceitável. Em suma, uma voz produzirá um vetor que aponta para uma determinada direção e sentido num espaço, vetores similares apontarão para essa mesma direção e sentido.

Embeddings de voz são representações vetoriais das características acústicas de um áudio. Que nos poupa de processar o áudio bruto (e features mais “pesadas”) e nos permite trabalhar apenas com representações matriciais desse áudio num espaço vetorial onde as vozes similares estão próximas e vozes distintas estarão distantes.

Transfer Learning foi a técnica utilizada na solução implementada neste trabalho, onde “o conhecimento de uma fonte é transferido para outra”. No nosso caso, utilizamos um *encoder* (ECAPA-TDNN, Desplanques, 2021) para extrair o “conhecimento” dos áudios da base de dados, para em seguida alimentarmos outro elemento (o classificador) com esse “conhecimento”, assim realizando a tarefa de classificação de locutores

3 - Modelo Implementado

3.1 - Encoder: ECAPA-TDNN como gerador de Embeddings


A Biblioteca Speechbrain fornece um [modelo pré treinado](#) capaz de extrair *embeddings* dos áudios fornecidos. O modelo é capaz de processar áudios em 16 kHz, e é capaz de fazer o *downsampling* dos áudios da LibriTTS (24 kHz -> 16 kHz), e extrair os *embeddings* dos áudios fornecidos, que são representações vetoriais das *features* dos áudios, o modelo foi utilizado no estado “congelado”, para fazer uso de sua capacidade pré-treinada afim de reduzir o tempo de treinamento de maneira significativa. O output dos áudios nada mais foram que vetores contínuos de 192 dimensões representativos das características discriminativas de cada voz onde ~30GB de áudios foram transformados em ~87MB.

3.2 - Classificador: Multi-Layer Perceptron

Uma rede neural feed-forward que recebe como input os embeddings de 192 dimensões gerados pelo Encoder e alimentados na rede. Essa rede através das camadas internas (hidden layers), projetam esses vetores num espaço de classes, fazendo com que a rede aprenda a classificar os vetores de entrada a cada locutor presente na base de dados LibriTTS.

3.3 - Modelo Completo

Esquematisação Da Arquitetura do Modelo



O modelo possui uma arquitetura híbrida de **Encoder-Classifer**, ou seja, o input de áudio da base LibriTTS é alimentado ao encoder (ECAPA-TDNN), onde o pré-processamento dos dados ocorreram para os embeddings serem gerados: *downsampling*, convertidos para mono e normalização de amplitude. Em seguida os *embeddings* foram alimentados para um **MultiLayer Perceptron** que classificou os vetores com algum locutor existente na base de dados.

4 - Resultados

4.1 - Base de Dados

A base de dados utilizada neste trabalho foi a [LibriTTS \(ZEN, 2019\)](#), que fornece aproximadamente 585 horas de áudio em inglês captados a 24 kHz em formato “.wav”, de 2456 locutores subdividido em bases menores para melhor conveniência.

Derivada da base de dados [LibriSpeech](#), que é uma base com áudios em .mp3 da base [LibriVox](#) e com transcrições de textos do [Project Gutenberg](#). Como base derivada de outras bases, alguns tratamentos foram feitos pelo desenvolvedor:

- Apenas áudios com taxa de amostragem em 24 kHz, convertidos do formato .mp3 para .wav, extraídos de 2456 locutores
- Fala dividida na quebra de frases

- Textos originais e normalizados incluídos
- Informações contextuais de frases vizinhas podem ser extraídas
- Falas com ruídos de fundo significativos foram excluídas

LibriTTS é fornecida pela Google LLC e licenciada sob Creative Commons Attribution 4.0 International License.

4.2 - Treinamento

1. Extração de embeddings
 - a. ~30GB de áudios -> ~87MB de embeddings
 - b. Reduz tempo de treinamento
 - c. Contém informações discriminativas dos áudios
2. Treinamento do Classificador
 - a. Batch Size: 128
 - b. Épocas: 50
 - c. Learning Rate: $1e-3$
 - d. Treinados na GPU através do CUDA.
 - e. Regularização
 - i. Dropout: 0.2 - 0.3
 - ii. Weight Decay: 0.01
 - iii. Batch Normalization
 - iv. Data Augmentation
 1. Aplicação de ruído de fundo
 2. Variações de volume

4.3 - Teste

O Experimento foi feito em dois subdatasets do LibriTTS, o train-clean-100 e o train-clean-360.

- train-clean-100
 - Amostras: 33.236
 - Locutores: 242
 - Splits: 70% train / 15% val / 15% test
 - Train: 23.265 / Val: 4.985 / Test: 4.984
- train-clean-360
 - Amostras: 116.251
 - Locutores: 871
 - Splits: 70% train / 15% val / 15% test

- Train: 81.373 / Val: 17.413 / Test: 17.465
- Locutores com menos de 5 samples foram retirados para poder fazer estratificação do dataset.

Experimento 1	test-clean-100
Test Accuracy	99.14%
Test Loss	0.0418
Confiança Média	99.12%
Amostras	4984
Acertos	4941
Erros	43
Taxa de Erro	0.86%

Experimento 2	test-clean-360
Test Accuracy	98.67%
Test Loss	0.0445
Confiança Média	99.17%
Amostras	17465
Acertos	17233
Erros	232
Taxa de Erro	1.33%

5- Conclusão

O projeto apresentou um modelo de identificação de Locutor implementado com uma arquitetura híbrida utilizando um encoder ECAPA-TDNN para extrair features de áudio e que treinaram um MLP como classificador para o domínio fornecido. O modelo conseguiu métricas consideradas boas para generalização do modelo, atingindo uma acurácia de 99.14% e

confiabilidade de 99.12% num dataset de 100h de áudio e acurácia de 98.67% e confiabilidade 99.17% num dataset de 360h.

Referências

Heiga Zen, Viet Dang, Rob Clark, Yu Zhang, Ron J. Weiss, Ye Jia, Zhifeng Chen, Yonghui Wu. (05 de Abril 2019). LibriTTS [Data set]. Em **LibriTTS: A Corpus Derived from LibriSpeech for Text-to-Speech**. <https://doi.org/10.48550/arXiv.1904.02882>

Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zach DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, Soumith Chintala. (2017). **Pytorch**. <https://pytorch.org/>

Desplanques, B., Thienpondt, J., & Demuynck, K. (2020). ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification. Em arXiv [eess.AS]. <http://arxiv.org/abs/2005.07143>

Krantz, T., & Jonker, A. (2025, novembro 17). Cosine similarity. lbm.com. <https://www.ibm.com/think/topics/cosine-similarity>

Gladia - how to build a speaker identification system for recorded online meetings. (s. d.). Gladia.io. Recuperado 15 de dezembro de 2025, de <https://www.gladia.io/blog/build-a-speaker-identification-system-for-online-meetings>

PyTorch Foundation. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. <https://pytorch.org/>

De Mori Yoshua Bengio, M. R. T. P. P. P. A. R. S. C. L. L. C. S. N. D. A. H. J. Z. J.-C. C. S.-L. Y. S.-W. F. C.-F. L. E. R. F. G. W. A. H. N. Y. G. R. (2021). SpeechBrain: A General-Purpose Speech Toolkit. <https://github.com/speechbrain/speechbrain>